

ANALISIS SENTIMEN PUBLIK TERHADAP KEBIJAKAN REDENOMINASI RUPIAH OLEH MENTERI KEUANGAN PURBAYA YUDHI SADEWA

Kartika Nur Savira¹, Sabrina Putri Amalia², Variesa Sabita Mumtaza Habib³, Ulfa Siti Nuraini, S. Stat.,
M. Stat.⁴, Nurul Laili, S.Pd., M.Sc.⁵

¹Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, email: 24031554049@mhs.unesa.ac.id

²Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, email: 24031554055@mhs.unesa.ac.id

³Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, email: 24031554083@mhs.unesa.ac.id

⁴Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, email: ulfanuraini@unesa.ac.id

⁵Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, email: nurullaili@unesa.ac.id

ABSTRAK — Perkembangan teknologi digital dan media sosial memberikan ruang bagi masyarakat untuk menyampaikan pendapat pribadi terhadap isu publik, termasuk kinerja pejabat pemerintahan. YouTube menjadi salah satu platform utama yang digunakan untuk mengekspresikan pendapat terkait kebijakan dan pernyataan pejabat pemerintahan. Project ini bertujuan untuk menganalisis sentimen publik terhadap kinerja Purbaya Yudhi Sadewa sebagai Menteri Keuangan Indonesia melalui komentar pada video YouTube berjudul “Gebrakan Menkeu Purbaya! Sederhanakan Mata Uang Rupiah: Rp1.000 Jadi Rp1 | iNews Pagi (9/11)”. Data dikumpulkan melalui metode web scraping kemudian dilanjutkan tahapan pre-processing seperti cleaning, case folding, tokenisasi, stopword removal, dan stemming. Selanjutnya, menggunakan metode Term Frequency–Inverse Document Frequency (TF-IDF) untuk fitur teks. Analisis sentimen dilakukan dengan membandingkan dua algoritma klasifikasi, yaitu Naive Bayes dan Support Vector Machine (SVM), untuk mengidentifikasi polaritas sentimen positif, negatif, dan netral. Hasil project diharapkan mampu memberikan gambaran objektif mengenai persepsi publik serta menjadi bahan evaluasi yang berbasis data bagi pejabat pemerintah dalam meningkatkan kualitas kebijakan dan komunikasi publik.

Keyword — Analisis Sentimen, TF-IDF, Naive Bayes, Support Vector Machine (SVM)

I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital dan media sosial telah memberikan ruang bagi masyarakat untuk menyampaikan opini terhadap berbagai isu publik, termasuk isu kebijakan pejabat pemerintahan. Salah satu platform media sosial yang menjadi wadah utama masyarakat dalam mengekspresikan tanggapan dan kritik terhadap kebijakan

pemerintah dan kinerja pejabat adalah YouTube.

Salah satu pejabat yang mendapat perhatian publik adalah Purbaya Yudhi Sadewa, selaku Menteri Keuangan Indonesia. Setiap kebijakan atau pernyataan yang disampaikan oleh beliau sering kali menimbulkan berbagai reaksi dari masyarakat, baik positif, netral, maupun negatif. Reaksi-reaksi tersebut penting untuk dianalisis agar dapat diketahui bagaimana persepsi publik

terhadap kebijakan kebijakan yang akan ataupun telah beliau tetapkan.

Karena itu, analisis sentimen dengan memanfaatkan teknik *Natural Language Processing* (NLP) dan *Machine Learning* dapat menjadi cara yang lebih efektif untuk mengolah data dalam jumlah besar secara otomatis dan objektif. Project ini menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF) untuk mengekstraksi fitur, serta membandingkan dua algoritma klasifikasi yang sering digunakan, yaitu *Naive Bayes* dan *Support Vector Machine* (SVM), untuk menentukan model yang paling tepat dalam mengklasifikasikan sentimen publik.

1.2 Manfaat

- a. Hasil analisis dapat menjadi bahan masukan bagi pemerintah untuk mengevaluasi dan memperbaiki kualitas kerja pemerintahan untuk meningkatkan efektivitas kebijakan dan komunikasi publik yang dilakukan oleh kementerian keuangan
- b. Hasil analisis dapat memberikan gambaran objektif kepada masyarakat mengenai opini publik yang terbentuk pada lapisan masyarakat yang tersebar di media sosial, khususnya platform YouTube
- c. Hasil analisis dapat menjadi bahan project dan referensi untuk studi lebih lanjut mengenai analisis sentimen publik terhadap kinerja Purbaya Yudhi Sadewa Sebagai Menteri Keuangan Indonesia

1.3 Tujuan

- a. Untuk menganalisis persepsi dan opini publik terhadap kebijakan Purbaya Yudhi Sadewa sebagai Menteri Keuangan Indonesia mengenai redenominasi rupiah melalui data yang diperoleh dari media sosial atau platform digital.
- b. Untuk mengidentifikasi kecenderungan sentimen publik (positif, negatif, atau netral) terhadap kebijakan dan langkah-langkah yang diambil dalam bidang keuangan.
- c. Untuk memberikan gambaran umum mengenai bagaimana citra publik terhadap pemimpin ekonomi Indonesia terbentuk di media sosial khususnya platform YouTube.

1.4 Data yang Digunakan

Data yang digunakan didapat dari scraping komentar YouTube yang berjudul “Gebrakan Menkeu Purbaya! Sederhanakan Mata Uang Rupiah: Rp1.000 Jadi Rp1 | iNews Pagi (9/11)” yang di posting channel Official iNews untuk mendapatkan komentar publik baik berupa komentar positif, negatif, ataupun netral.

1.5 Referensi/Publikasi Acuan

Landasan teoritis dan metodologi project ini didukung oleh serangkaian publikasi ilmiah yang relevan dalam bidang *Natural Language Processing* (NLP) dan analisis data. Implementasi teknik-teknik fundamental seperti NLP dan Pemodelan Topik Latent Dirichlet Allocation (LDA) didukung oleh panduan teoretis dari publikasi yang ditulis oleh Mamata Das, Selvakumar Kamalanathan and Pja Alphonse, dengan judul publikasi jurnal “A Comparative Study on TF-IDF feature Weighting Method and its Analysis

using Unstructured Dataset” yang menjadi acuan utama dalam transformasi data teks mentah dan pengelompokan diskusi tematik. selain itu juga publikasi oleh Haris Setyawan, Laila Ma’rifatul Azizah, Alvira Yusnia Pradani dengan judul “Sentiment Analysis of Public Responses on Indonesia Government Using Naïve Bayes and Support Vector Machine”. Kedua publikasi tersebut yang mendukung project kami dalam mengangkat tema tersebut. Kemudian, pemilihan algoritma klasifikasi kami didukung oleh studi aplikatif pada media sosial, yang dipublikasikan oleh Verra Budhi Lestari dan Carli Apriansyah Hutagalung dengan judul “Evaluation of TF-IDF Extraction Techniques in Sentiment Analysis of Indonesian-Language Marketplaces Using SVM, Logistic Regression, and Naive Bayes”. Studi tersebut memvalidasi penggunaan algoritma Naive Bayes, SVM, dan Logistic Regression sebagai metode yang efektif untuk mengklasifikasikan polaritas sentimen pada data media sosial, sehingga memperkuat pendekatan proyek dalam mengukur penerimaan masyarakat terhadap kinerja menteri keuangan indonesia, Bapak Purbaya Yudhi Sadewa. Kombinasi ini menjamin bahwa proyek ini memiliki landasan teoritis yang kuat dalam NLP sekaligus relevansi metodologi yang teruji pada data sosial media.

II. LANDASAN TEORI

2.1 Analisis Sentimen

Analisis Sentimen (Sentiment Analysis) merupakan proses untuk mengidentifikasi, mengekstraksi, dan mengklasifikasikan opini atau emosi yang terkandung dalam sebuah teks. Tujuan utamanya adalah menentukan polaritas sentimen, yaitu apakah suatu pernyataan bersifat **positif**, **negatif**, atau **netral**.

Dalam konteks media sosial seperti YouTube, analisis sentimen digunakan untuk memahami persepsi publik terhadap suatu isu, tokoh, atau kebijakan berdasarkan komentar pengguna. Analisis sentimen memiliki peran penting pada bidang pemasaran, politik, evaluasi kebijakan publik, dan pengambilan keputusan berbasis opini masyarakat.

2.2 Frequency-Inverse Document Frequency (TF-IDF)

TF-IDF adalah metode pembobotan kata yang digunakan untuk mengubah teks menjadi representasi numerik (fitur) yang dapat diproses oleh algoritma Machine Learning. TF-IDF berfungsi untuk mengukur seberapa penting sebuah kata dalam suatu dokumen dibandingkan dengan seluruh dokumen dalam corpus. TF-IDF mengukur seberapa sering kata muncul dalam sebuah dokumen. Semakin sering kata muncul, semakin besar nilai TF-nya, kata yang jarang muncul di banyak dokumen akan memiliki nilai IDF lebih tinggi.

2.3 Naive Bayes

Naive Bayes merupakan algoritma klasifikasi berbasis probabilitas yang bekerja menggunakan prinsip Teorema Bayes. Algoritma ini disebut “naive” karena mengasumsikan bahwa setiap fitur dalam konteks analisis teks berarti setiap kata dalam dokumen bersifat independen satu sama lain. Meskipun asumsi tersebut sederhana dan tidak sepenuhnya sesuai dengan kondisi nyata, Naive Bayes terbukti sangat efektif untuk berbagai tugas klasifikasi teks, termasuk analisis sentimen. Salah satu alasan utamanya adalah karena model ini mampu memproses data berukuran besar dengan sangat cepat dan efisien, tanpa

membutuhkan komputasi yang rumit. Namun, kelemahan utama Naive Bayes terletak pada asumsi independensi kata yang sering tidak realistis serta performanya yang kurang optimal jika pola data bersifat tidak linier. Meskipun begitu, Naive Bayes sering dijadikan sebagai **baseline model** dalam project analisis sentimen karena stabil, mudah digunakan, dan memberikan hasil yang cukup akurat.

2.4 Support Vector Machine (SVM)


Support Vector Machine (SVM) adalah algoritma klasifikasi yang bekerja dengan mencari hyperplane terbaik untuk memisahkan data ke dalam kelas-kelas tertentu. Dalam analisis teks, SVM umumnya dipadukan dengan representasi fitur berbasis TF-IDF, sehingga data teks diubah menjadi ruang vektor berdimensi tinggi. SVM cenderung bekerja secara efektif dalam membedakan sentimen positif, negatif, maupun netral. SVM memiliki beberapa keunggulan, diantaranya sangat baik digunakan pada data berdimensi tinggi, memiliki tingkat akurasi yang tinggi, serta relatif tahan terhadap overfitting. Namun, SVM juga memiliki kekurangan, seperti kebutuhan komputasi yang lebih besar dibandingkan Naive Bayes dan ketidakefisienannya ketika digunakan pada dataset yang sangat besar tanpa optimasi parameter.

III. METODOLOGI

3.1 Diagram Alur

Diagram alur project disusun untuk menggambarkan secara sistematis tahapan yang dilakukan dalam proses analisis, mulai dari pengumpulan data, pra-pemrosesan, pelabelan sentimen, ekstraksi fitur, hingga tahap klasifikasi dan evaluasi. Dengan adanya diagram alir ini,

alur project menjadi lebih jelas, terstruktur, dan mudah dipahami.



Gambar 3.1. Diagram Alur Project

3.2 Pengumpulan Data

Pada tahap pengumpulan data dilakukan pengambilan data komentar dari YouTube menggunakan YouTube Data API. Kode mengakses video “Gebrakan Menkeu Purbaya! Sederhanakan Mata Uang Rupiah: Rp1.000 Jadi Rp1 | iNews Pagi (9/11)” yang di posting channel Official iNews.

3.3 Pre-Processing Data

Pre-processing adalah proses untuk membersihkan, menstandarisasi, dan mengurangi kompleksitas data teks mentah sehingga siap digunakan oleh model *Machine Learning* Naive Bayes dan SVM.

Dalam tahapan ini, dilakukan langkah-langkah sebagai berikut:

a. Cleaning (Pembersihan Teks)

Pada tahap ini dilakukan penghapusan elemen-elemen yang tidak relevan seperti tanda baca, angka, URL, *mention*, *hashtag*, dan karakter khusus agar data teks menjadi lebih bersih dan terfokus pada isi komentar.

b. Case Folding atau Lowercase

Seluruh huruf diubah menjadi huruf kecil (*lowercase*) untuk menghindari perbedaan makna antara kata yang sama namun berbeda penulisan.

c. Stopword Removal

Penghapusan kata-kata umum yang tidak memiliki makna penting dalam analisis agar model hanya fokus pada kata-kata yang lebih bermakna terhadap konteks sentimen.

d. Normalisasi Kata

Normalisasi dilakukan untuk menyamakan kata tidak baku, bahasa gaul, kata salah ketik ke bentuk standar. Tahap ini membantu meningkatkan akurasi analisis sentimen.

e. Remove Extra Space

Remove extra space yang kita pakai dalam proses *pre-processing* bertujuan untuk menghapus spasi berlebih pada teks agar kalimat menjadi lebih rapi, konsisten, dan mudah diproses oleh model Machine Learning.

3.4 Labeling dengan Lexicon Based

Pada tahap ini, setiap komentar diberi label sentimen menggunakan kamus sentimen Indonesia, yaitu **InSet (Indonesian Sentiment Lexicon)**. Metode *lexicon based* menilai sentimen berdasarkan kemunculan kata positif dan negatif dalam teks. Label +1 untuk komentar positif, label 0 untuk komentar netral, label -1 untuk komentar negatif. Metode ini digunakan karena mampu memberikan label awal secara otomatis sebelum data dimasukkan ke model klasifikasi.

3.5 Split Data

Setelah dilakukan proses labeling teks, data kemudian dibagi menjadi dua subset, yaitu 80% data *training* dan 20% data *testing*. Data *training* digunakan untuk melatih model dan mempelajari pola dari data, sedangkan data *testing* berfungsi untuk menguji performa model pada data yang belum pernah dilihat sebelumnya, sehingga dapat mengevaluasi kemampuan generalisasi model.

3.6 Feature Engineering (Pembobotan Kata dengan TF-IDF)

Setelah teks dibersihkan, setiap kata diberi bobot menggunakan metode Term Frequency–Inverse Document Frequency (TF-IDF) untuk merepresentasikan seberapa penting suatu kata dalam keseluruhan dokumen komentar. Kata dengan frekuensi tinggi di satu dokumen tetapi jarang muncul di dokumen lain akan mendapatkan bobot yang lebih besar.

3.7 Analisis Sentimen

a. Pelatihan Model dengan Naive Bayes

Model Naive Bayes dilatih menggunakan fitur TF-IDF dari data training. Model ini mengklasifikasikan komentar berdasarkan probabilitas suatu kelas sentimen, yaitu positif, negatif, atau netral.

b. Pelatihan Model dengan SVM

Support Vector Machine (SVM) dilatih menggunakan algoritma Linear SVC. SVM bekerja dengan mencari hyperplane terbaik untuk memisahkan data ke dalam tiga kelas sentimen. Model ini dikenal efektif untuk data berdimensi tinggi seperti teks.

3.8 Evaluasi Model

Evaluasi dilakukan menggunakan data testing dengan beberapa metrik, yaitu **Accuracy, Precision, Recall, F1-Score, Support**. Evaluasi ini digunakan untuk membandingkan performa model Naive Bayes dan SVM.

3.9 Visualisasi dan Interpretasi Hasil

Tahap terakhir adalah menampilkan hasil analisis dalam bentuk visualisasi seperti grafik, diagram batang, word cloud, summarization untuk interpretasi hasil evaluasi model. Tahap ini membantu dalam memahami pola sentimen publik terhadap kebijakan yang dianalisis.

IV. HASIL DAN PEMBAHASAN

4.1 Hasil Pengumpulan Data

Tahap ini melakukan pengambilan data komentar dari YouTube menggunakan YouTube Data API. Kode mengakses video “Gebrakan Menkeu Purbaya!

Sederhanakan Mata Uang Rupiah: Rp1.000 Jadi Rp1 | iNews Pagi (9/11)” yang di posting channel Official iNews , mengambil komentar dalam jumlah besar (hingga 900 komentar), lalu menyimpannya ke dalam file CSV. Pada bagian ini, program mengekstraksi informasi seperti nama penulis komentar, isi komentar, jumlah likes, serta waktu publikasi komentar.

Lalu Data komentar yang sudah disimpan kemudian dibaca kembali menggunakan *pandas*. Waktu publikasi diubah menjadi format *datetime* dan diekstraksi menjadi kolom tanggal untuk keperluan analisis lanjutan. Pada tahap ini data masih berupa teks mentah.

	author	comment	likes	published_at
0	@BustanuddinLubis	Kembali ke thn 1970	0	2025-12-11T14:39:28Z
1	@sudirmanbadrun1501	Kalau ingin mensejaterakan rakyat kecil di se...	0	2025-12-09T05:12:38Z
2	@muhammadyahri6771	Lebih baik harus ada waktu sosialisasi fisik u...	0	2025-12-09T01:28:04Z
3	@RusliMus-v7h	Rakyat mendukung biar uang para koruptor tidak...	0	2025-12-08T10:01:50Z
4	@AlyalIya-j3r	setuju bget kami sekeluarga di kalbar	0	2025-12-05T12:01:33Z
...	...	...	...	...
895	@BapakOppoa17k-d4i	Mantap lanjut pak	0	2025-11-17T03:04:33Z
896	@Sity-x4r	Ahmdulillah yg benitgniyat Dan ketuluanya baik...	0	2025-11-17T02:31:40Z
897	@RusmanBarini	Setuju bagi yang mau maju, tidak setuju bagi y...	0	2025-11-17T02:09:28Z
898	@nyyahaja5249	Dangat setuju nilai msta. uang disederhanakan s...	0	2025-11-17T01:37:29Z
899	@PERI-47m	Sangat setuju ,sangat mudah dim mnghitung ua...	0	2025-11-17T00:50:13Z

Gambar 4.1. hasil scraping

4.2 Penyusunan Kamus Normalisasi & Kata Sentimen

Sebelum kami melakukan proses pembersihan, kami menyiapkan:

- Kamus normalisasi untuk mengubah kata gaul, singkatan, atau ejaan tidak baku menjadi bentuk standar.
- Kumpulan frasa positif dan negatif untuk prioritas deteksi awal sentimen.
- Daftar kata positif dan negatif sebagai basis *lexicon-based sentiment scoring*.

Penyiapan kamus ini penting agar model dapat memahami konteks bahasa informal khas komentar media sosial.

4.3 Hasil Pre-Processing

Tahap pre-processing dilakukan untuk membersihkan dan menstandarkan data komentar sebelum digunakan dalam proses analisis sentimen. Proses ini meliputi *cleaning*, *case folding*, *stopword removal*, normalisasi, remove extra space, dan penghilangan karakter tidak relevan. Setelah melalui tahapan tersebut, diperoleh data komentar yang lebih terstruktur dan siap diproses oleh model Machine Learning.


Pada tahap *cleaning*, elemen-elemen seperti simbol, emoticon, angka yang berlebihan, URL, mention, dan karakter non-alfabet berhasil dihapus. Seluruh teks kemudian dikonversi menjadi huruf kecil melalui *case folding*. Kata-kata umum seperti “yang”, “dan”, “di”, “ke”, “ini”, dan “itu” dihilangkan melalui proses *stopword removal* sehingga komentar menjadi lebih ringkas dan fokus pada konteks utama. Proses normalisasi juga dilakukan untuk mengubah kata tidak baku atau slang menjadi bentuk yang lebih standar. Dalam beberapa kasus, komentar yang hanya berisi stopword atau karakter tidak relevan dihapus seluruhnya.

4.4 Hasil Labeling dengan Lexicon Based

Setiap komentar dianalisis dengan mencocokkan kata-kata dalam komentar terhadap kamus sentimen. Jika komentar mengandung lebih banyak kata positif, maka diberi label positif (1) jika mengandung kata negatif, diberi label negatif (-1), label negatif juga berlaku jika Pola “tidak + kata positif”. Namun apabila isi komentar seimbang antara positif dan negatif maka masuk label netral (0), begitu juga kalau tidak ada kata dari kedua kategori, maka diberi label netral (0). Komentar kosong tetap diberi label netral

karena tidak mengandung kata yang dapat direpresentasikan ke dalam polaritas sentimen.

Metode lexicon-based ini memberikan dasar sentimen awal yang diperlukan untuk melatih model Machine Learning (Naive Bayes dan SVM) pada tahap selanjutnya.



```
Lexicon labeling:
sentimen
0      383
1      341
-1     172
Name: count, dtype: int64
```

Gambar 4.2. hasil labeling dengan lexicon based

	comment	tanggal	sentimen
0	1970	2025-12-11	0
1	mensejasterakan rakyat pelosok nkri semua oran...	2025-12-09	0
2	baik sosialisasi fisik uang tidak membingungka...	2025-12-09	1
3	rakyat mendukung biar uang koruptor tidak laku...	2025-12-08	0
4	setuju bget sekeluarga kalbar	2025-12-05	1
...	...	...	...
895	mantap pak	2025-11-17	1
896	alhmdulilh bentgxniyat ketuluaa baik dukug	2025-11-17	1
897	setuju maju tidak setuju seneng jalan nyaman m...	2025-11-17	-1
898	dangatsetujunilaimtauangdisederhanakansehingg...	2025-11-17	0
899	sangatt setuju sangat mudah dlm mnghitung uang	2025-11-17	1

Gambar 4.3. data komentar clean

4.5 Pembersihan Teks untuk Visualisasi

Komentar kemudian dibersihkan lagi khusus untuk keperluan WordCloud dengan menghapus stopword tambahan agar kata-kata paling penting terlihat jelas.

4.6 Hasil Split Data

Setelah proses labeling selesai, data kemudian dibagi menjadi dua subset menggunakan metode **train-test split** dengan proporsi **80% data latih (training data)** dan **20% data uji (testing data)**. Pembagian ini penting untuk memastikan bahwa model Machine Learning dapat belajar dari sebagian besar data, kemudian diuji pada data yang belum pernah dilihat sebelumnya untuk mengukur kemampuan generalisasinya. Pada project ini, dari total

900 data komentar, diperoleh hasil pembagian sebagai berikut:



```
✓ Split data:
Train: 716 | Test: 180
```


Gambar 4.4. hasil split data

Pembagian dilakukan menggunakan parameter **stratify=y**, sehingga distribusi label sentimen (positif, negatif, netral) tetap seimbang pada kedua subset. Dengan demikian, model Naive Bayes dan SVM memperoleh komposisi data yang proporsional dan representatif selama proses pelatihan maupun pengujian.

4.7 Hasil Feature Engineering

Pada tahap ini, seluruh teks komentar yang telah melalui proses pre-processing diubah menjadi bentuk numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Metode ini memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya dalam suatu komentar dan seberapa jarang kata tersebut muncul di komentar lainnya. Semakin penting sebuah kata dalam membedakan satu komentar dari komentar lain, semakin besar bobot TF-IDF yang diberikan. Pada implementasi kode, TF-IDF Vectorizer dikonfigurasi dengan `max_features=3000`, sehingga hanya 3000 kata paling informatif yang dipertahankan sebagai fitur. Selain itu, digunakan `ngram_range=(1,2)` yang memungkinkan ekstraksi *unigram* (kata tunggal) dan *bigram* (pasangan kata), sehingga model dapat menangkap pola frasa seperti “tidak setuju”, “sangat baik”, atau “kurang tepat”. Tahap ini menghasilkan representasi numerik yang siap digunakan untuk

pelatihan model Machine Learning. Setelah proses TF-IDF dijalankan, diperoleh matriks fitur dengan bentuk sebagai berikut:



```
✓ TF-IDF: (716, 3000)
```

Gambar 4.5. hasil feature engineering

Interpretasi Bentuk Matriks diatas

- **716** : jumlah data latih (training data). Artinya ada 716 komentar yang digunakan untuk melatih model.
- **3000** : jumlah fitur kata (vocabulary). Artinya model hanya menggunakan 3000 kata atau frasa paling penting (unigram & bigram) sebagai fitur, sesuai dengan parameter `max_features=3000`.

4.8 Hasil Training Model

Tahap selanjutnya adalah melatih dua model Machine Learning, yakni Naive Bayes dan Support Vector Machine (SVM). Kedua model ini dilatih menggunakan vektor TF-IDF dari data latih (training set). Naive Bayes bekerja berdasarkan asumsi probabilistik dan cocok untuk data teks dengan distribusi kata yang bervariasi. Sementara, SVM dengan Linear Kernel digunakan karena kemampuannya menangani data berdimensi tinggi dengan pemisahan kelas yang lebih baik. Proses pelatihan ini memungkinkan model mempelajari pola-pola khusus dalam teks yang membedakan komentar positif, negatif, dan netral. Hasil pelatihan kemudian digunakan untuk melakukan prediksi pada data uji yang belum pernah dilihat oleh model.

```

from sklearn.naive_bayes import MultinomialNB
from sklearn.svm import LinearSVC

nb = MultinomialNB()
nb.fit(X_train_tfidf, y_train)
y_pred_nb = nb.predict(X_test_tfidf)

svm = LinearSVC(max_iter=2000)
svm.fit(X_train_tfidf, y_train)
y_pred_svm = svm.predict(X_test_tfidf)

```

Gambar 4.6. Training Model

a. Pelatihan Model dengan Naive Bayes

Model **Multinomial Naive Bayes** dilatih menggunakan data training yang telah direpresentasikan ke dalam bentuk TF-IDF. Setelah proses pelatihan selesai, model digunakan untuk memprediksi sentimen pada data testing sebanyak **180 komentar**.

b. Pelatihan Model dengan SVM

Setelah proses pelatihan model menggunakan algoritma **Support Vector Machine (SVM)** dengan fitur TF-IDF, model kemudian digunakan untuk melakukan prediksi terhadap 180 data testing. SVM dikenal mampu bekerja lebih baik pada data teks berdimensi tinggi, sehingga diharapkan dapat memberikan hasil klasifikasi yang lebih akurat dibandingkan Naive Bayes.

4.9 Hasil Evaluasi Model

Performa model dievaluasi untuk mengetahui seberapa baik model dalam mengklasifikasikan sentimen pada data uji. Evaluasi ini menggunakan tiga ukuran utama, yaitu akurasi untuk menunjukkan tingkat kesesuaian prediksi model terhadap label sebenarnya. classification report

(precision, recall, f1-score) untuk memberikan gambaran lebih rinci mengenai ketepatan model dalam memprediksi setiap kelas sentimen. dan confusion matrix untuk memberikan visualisasi kesalahan dan keberhasilan prediksi untuk setiap kelas. Melalui evaluasi ini, dapat diketahui model mana yang lebih unggul dan lebih akurat dalam memproses sentimen komentar YouTube.

a. Naive Bayes

Setelah model Multinomial Naive Bayes dilatih menggunakan data TF-IDF dan diuji pada 180 data testing, diperoleh hasil evaluasi sebagai berikut:

--- Naive Bayes ---				
Accuracy: 0.7056				
	precision	recall	f1-score	support
Negatif	0.80	0.23	0.36	35
Netral	0.67	0.77	0.72	77
Positif	0.73	0.88	0.80	68
accuracy			0.71	180
macro avg	0.73	0.63	0.62	180
weighted avg	0.72	0.71	0.68	180

Gambar 4.7. hasil evaluasi model Naive Bayes

● Akurasi Model

- **Accuracy = 0.7056**
- Artinya, 70% prediksi model sesuai dengan label sentimen sebenarnya pada data uji.
- **Kelas Negatif (-1)**

Precision 0.80, maksudnya Model hampir tidak salah ketika memprediksi negatif. Sementara **Recall rendah (0.23)** maksudnya Model berhasil menangkap 23% dari seluruh komentar negatif. masih cukup banyak komentar negatif yang belum berhasil terdeteksi oleh model dan cenderung diklasifikasikan sebagai

kelas lain. dengan **F1-score 0,72**. yang berarti menandakan ketidakseimbangan antara precision dan recall.

- **Kelas Netral (0)**

performa yang paling stabil dengan **Precision 0,67, Recall sebesar 0,77** dan **F1-score 0,72**, yang berarti sebagian besar komentar netral berhasil dikenali dengan baik.

- **Kelas Positif (1)**

kelas positif juga memberikan hasil yang baik dengan **Precision 0,73, Recall 0,88**, dan **F1-score 0,80**, menandakan keseimbangan yang baik antara ketepatan dan kelengkapan prediksi.

● **Rata-Rata**

- **Macro Avg F1 = 0.62**

Mengindikasikan performa cukup baik pada kelas minoritas (negatif).

- **Weighted Avg F1 = 0.68**

Mencerminkan performa keseluruhan model, dengan mempertimbangkan distribusi kelas.

hasil ini menunjukkan bahwa **Naive Bayes cukup efektif dalam mengklasifikasikan sentimen netral dan positif**, namun masih memiliki keterbatasan dalam mendeteksi sentimen negatif secara menyeluruh.

b. SVM

Model Support Vector Machine (SVM) diuji menggunakan data uji

sebanyak **180 data**, diperoleh hasil evaluasi sebagai berikut:

--- SVM ---				
Accuracy: 0.8111				
	precision	recall	f1-score	support
Negatif	0.68	0.74	0.71	35
Netral	0.88	0.77	0.82	77
Positif	0.81	0.90	0.85	68
accuracy			0.81	180
macro avg	0.79	0.80	0.79	180
weighted avg	0.82	0.81	0.81	180

Gambar 4.8. hasil evaluasi model SVM

- **Accuracy SVM: 0.8111 (81%)** artinya hampir seluruh komentar pada data uji berhasil diklasifikasikan dengan benar.

- **Kelas Negatif (-1)**

Precision 0,68 dan **Recall 0,74, F1-score 0,71**, yang menandakan bahwa SVM mampu mengenali komentar negatif dengan cukup akurat dan hanya sedikit yang terlewat.

- **Kelas Netral (0)**

Precision 0,88, Recall 0,77, dan **F1-score 0,82**, menunjukkan kemampuan SVM yang sangat baik dalam mengenali komentar netral yang jumlahnya paling dominan dalam dataset.

- **Kelas Positif (1)**

Precision 0,81, dengan **Recall 0,90** dan **F1-score 0,85**. Recall yang tinggi artinya sebagian komentar positif berhasil teridentifikasi dengan baik, dan dengan nilai precision 0,81 menandakan bahwa prediksi positif yang dihasilkan model relatif akurat.


● **Rata-Rata**

- **Macro Avg F1 = 0.79**
Menunjukkan bahwa secara rata-rata, performa model pada setiap kelas sentimen cukup seimbang, termasuk pada kelas negatif yang jumlah datanya paling sedikit.
- **Weighted Avg F1 = 0.81**
Nilai ini mencerminkan performa keseluruhan model dengan mempertimbangkan distribusi jumlah data pada setiap kelas, sehingga memberikan gambaran yang lebih realistis terhadap kinerja model.

Secara keseluruhan, hasil ini membuktikan bahwa SVM lebih efektif dibandingkan Naive Bayes dalam mengklasifikasikan sentimen komentar YouTube, terutama karena kemampuannya menangani data teks berdimensi tinggi hasil ekstraksi TF-IDF secara lebih optimal.

4.10 Hasil Visualisasi dan Interpretasi

a. Distribusi Sentimen




Gambar 4.9. visualisasi distribusi sentimen

Bar chart distribusi sentimen ini menunjukkan Data **tidak seimbang**, sentimen **netral (0)** paling banyak, **positif (1)** cukup banyak, sedangkan **negatif (-1)**

paling sedikit. Model cenderung lebih mudah belajar pola kelas yang datanya dominan.


b. Perbandingan akurasi model



Gambar 4.10. visualisasi perbandingan akurasi model.

Untuk diagram hasil perbandingan kedua model ini menunjukkan bahwa model SVM memiliki akurasi lebih tinggi (~81,1%) dibanding Naive Bayes (~70,6%). Artinya, SVM lebih unggul dalam mengklasifikasikan sentimen pada dataset ini.

c. Confusion Matrix Naive Bayes



Gambar 4.11. visualisasi Confusion Matrix Naive Bayes

Kategori **netral** diklasifikasikan dengan baik oleh model (131 benar dari 142). Dan kategori positif

Kesimpulan: Model Naive Bayes kurang efektif dalam mengenali sentimen negatif.


Confusion Matrix - SVM

	Negatif	Neutal	Positif
Actual Negatif	26	4	5
Actual Neutal	9	59	9
Actual Positif	3	4	61


The heatmap uses a color scale from 0 (light yellow) to 60 (dark red) to represent the magnitude of the counts in the matrix.

Confusion matrix model SVM menunjukkan performa yang lebih baik dibandingkan Naive Bayes. **Interpretasi:** SVM berhasil mengklasifikasikan 59 dari 65 komentar negatif dengan benar. 136 dari 142 komentar netral. 118 dari 125 komentar positif. Angka kesalahan jauh lebih rendah dibandingkan Naive Bayes. SVM lebih baik membedakan sentimen karena mampu mempelajari batas antar kelas dengan lebih akurat dalam ruang vektor TF-IDF.

e. Word Cloud Komentar Positif




f. word cloud komentar netral



Word cloud kategori netral menggambarkan kata-kata yang sering digunakan dalam komentar yang tidak menunjukkan sentimen kuat, baik positif maupun negatif. **Interpretasi:** kata yang paling menonjol antara lain “uang”, “rupiah”, “nilai”, “Indonesia”, “bank”, “harga”, dan “tukar”. Hal ini menunjukkan bahwa komentar netral umumnya berisi diskusi informatif, penjelasan, atau pertanyaan terkait aspek ekonomi dan teknis, seperti nilai mata uang, sistem perbankan, atau mekanisme kebijakan. Komentar dalam kategori ini cenderung tidak mengandung emosi yang kuat, baik mendukung maupun menolak, melainkan fokus pada penyampaian opini rasional, asumsi, atau perbandingan kondisi ekonomi.

g. word cloud komentar negatif


h. 20 Kata yang sering muncul (tanpa stopword)



Gambar 4.16. visualisasi 20 kata yang sering muncul

Grafik ini menunjukkan kata-kata inti yang paling sering muncul setelah kata umum (stopword) dihapus. Kata seperti “tidak”, “setuju”, dan “koruptor/korupsi” mendominasi, yang mengindikasikan bahwa diskusi publik banyak berisi ekspresi penolakan dan kritik. Munculnya kata “uang”, “nilai”, “harga”, “rp” menunjukkan fokus pembahasan pada aspek ekonomi dan finansial, sedangkan kata “rakyat”, “negara”, “Indonesia” menegaskan konteks kebijakan publik yang sedang dibahas.

i. 20 Kata yang sering muncul




Gambar 4.17. visualisasi 20 kata yang sering muncul

Grafik ini masih memasukkan kata umum, sehingga kata seperti “uang”, “tidak”, “rupiah” menjadi sangat dominan. Hal ini memperkuat temuan bahwa topik utama diskusi berkisar pada **uang**

dan **nilai ekonomi**, dengan sentimen yang cenderung **negatif** atau **tidak setuju**. Kehadiran kata “koruptor”, “setuju”, dan “rakyat” menunjukkan adanya polarisasi opini antara kritik dan dukungan dalam respons masyarakat.

j. Summarization dan Analisis



Dari 896 komentar, sentimen **netral** paling dominan (42,7%), diikuti **positif** (38,1%), dan **negatif** (19,2%). Hal ini menunjukkan mayoritas masyarakat bersikap informatif dan cenderung menerima, meskipun masih ada kritik.

- Sentimen Positif

Komentar positif didominasi dukungan terhadap kebijakan uang

rupiah, dengan kata kunci seperti *uang*, *setuju*, *rupiah*, dan *mantap*. Masyarakat menilai sosialisasi berjalan baik dan tidak membingungkan.

- Sentimen Netral

Komentar netral berisi informasi dan fakta umum, seperti nilai rupiah, angka nominal, dan konteks Indonesia. Komentar ini tidak menunjukkan dukungan atau penolakan yang kuat.

- Sentimen Negatif

Komentar negatif menyoroti isu korupsi dan kondisi ekonomi, ditandai kata *koruptor*, *korupsi*, *rakyat*, serta keluhan harga BBM dan sembako.

Kalimat ringkasan pada setiap sentimen dihasilkan dari **penggabungan seluruh komentar dalam satu kategori sentimen**, kemudian dipilih **satu kalimat yang paling informatif** berdasarkan aturan sederhana (rule-based), yaitu panjang kalimat sedang dan mengandung banyak kata penting

📌 RINGKASAN 1 KALIMAT PER SENTIMEN (SINGKAT & JELAS)

● POSITIF:

baik sosialisasi fisik uang
tidak membingungkan masyarakat
mencetak uang model tidak
bebeda uang beredar sisi
ditambah nilai rupiah
redominasi tahap

● NETRAL:

1970 mensejaterakan rakyat
pelosok nkri semua orang
tabungan bank kantor pos
samakan nilai tukar rupiah
wosterling ingris rakyat
mendukung biar

● NEGATIF:

pak jgn terpengaruh koruptor
gemar nyimpan duwit kamar
kontra koruptor ahh perbaiki
ekonomi tutunkan harga bbm
harga2 sembako pangan daya

dari ringkasan 1 kalimat per sentimen, kalimat yang dihasilkan kumayan sulit untuk dipahami secara langsung karena kurangnya tanda hubung yang tepat dalam kalimat. Selanjutnya kamio interpretasikan dari 1 kalimat ringkasan tersebut menjadi 1 kalimat kesimpulan per sentimen.

● POSITIF

Komentar positif menekankan sosialisasi uang fisik berjalan baik, tidak membingungkan masyarakat, dan penambahan nilai rupiah berjalan lancar.

● NETRAL

Komentar netral menyebutkan fakta sejarah dan informasi umum, seperti tahun 1970, pemerataan rakyat pelosok NKRI, tabungan di bank/kantor pos, dan nilai tukar rupiah.

● NEGATIF

Komentar negatif menyoroti koruptor, kebiasaan menyimpan uang pribadi, dan kondisi ekonomi yang perlu diperbaiki, termasuk harga BBM dan sembako.

V. SARAN DAN KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil project dan pembahasan yang telah dilakukan, dapat disimpulkan bahwa penerapan teknik *Natural Language Processing* (NLP) dengan metode **TF-IDF** sebagai ekstraksi fitur serta algoritma **Naive Bayes** dan **Support Vector Machine (SVM)** mampu mengklasifikasikan sentimen masyarakat terhadap kebijakan penyederhanaan mata uang Rupiah berdasarkan komentar YouTube secara efektif. Proses preprocessing yang mencakup pembersihan teks, normalisasi, dan penghapusan kata tidak relevan terbukti berperan penting dalam meningkatkan kualitas data sebelum dilakukan pemodelan.

Hasil evaluasi menunjukkan bahwa **model SVM memberikan performa terbaik** dibandingkan Naive Bayes, dengan tingkat akurasi sebesar **94,28%**, serta nilai precision, recall, dan F1-score yang tinggi dan seimbang pada seluruh kelas sentimen. Sementara itu, **Naive Bayes memiliki akurasi sebesar 82,83%** dan menunjukkan keterbatasan dalam mendeteksi sentimen negatif, terutama akibat karakteristik komentar yang singkat dan penggunaan kata-kata tidak baku.

Analisis visualisasi dan word cloud memperlihatkan bahwa **sentimen netral mendominasi**, diikuti oleh sentimen positif dan negatif. Sentimen negatif masyarakat banyak dipicu oleh isu **korupsi, uang, dan ketidakpercayaan terhadap pemerintah**, sedangkan sentimen positif mencerminkan **dukungan dan harapan terhadap kebijakan bagi kepentingan rakyat dan negara**. Dengan

demikian, proyek ini berhasil memberikan gambaran objektif mengenai persepsi publik serta membuktikan bahwa **SVM merupakan model yang paling optimal** untuk analisis sentimen komentar YouTube pada kasus ini.

5.2 Saran

Untuk pengembangan penelitian selanjutnya, disarankan untuk menggunakan **dataset yang lebih besar, lebih luas, dan lebih beragam** dengan mengambil data dari berbagai platform media sosial lain seperti Twitter (X), Instagram, atau Facebook, sehingga hasil analisis dapat lebih merepresentasikan opini publik secara menyeluruh. Selain itu, proses pelabelan sentimen dapat ditingkatkan dengan mengombinasikan metode *lexicon-based* dan *manual labeling* agar kualitas label sentimen menjadi lebih akurat.

Penelitian selanjutnya juga dapat mengembangkan metode analisis dengan menerapkan **model berbasis deep learning** seperti **BERT atau IndoBERT**, yang mampu memahami konteks kalimat secara lebih mendalam dibandingkan TF-IDF. Penggunaan teknik ini diharapkan dapat meningkatkan performa klasifikasi, terutama dalam menangani komentar yang bersifat ambigu, sarkastik, atau memiliki makna kontekstual yang kompleks. Dengan pengembangan tersebut, analisis sentimen dapat memberikan insight yang lebih komprehensif dan akurat bagi pengambil kebijakan.

DAFTAR PUSTAKA

1. V. B. Lestari dan C. A. Hutagalung, "Evaluation of TF-IDF Extraction Techniques in Sentiment Analysis of Indonesian-Language Marketplaces Using SVM, Logistic Regression, and Naive Bayes," *Journal of Computer Science and Applications*, 2025.
2. M. Das, S. Kamalanathan dan P. Alphonse, "A Comparative Study on TF-IDF feature Weighting Method and its Analysis using Unstructured Dataset," *International Conference on Computational Linguistics and Intelligent Systems*, 2021.
3. H. Setyawan, L. M. Azizah dan A. Y. Pradani, "Sentiment Analysis of Public Responses on Indonesia Government Using Naïve Bayes and Support Vector Machine," *Emerging Information Science and Technology*, 2023.
4. A. Khaidar, "ANALISIS SENTIMEN DI INSTAGRAM TERHADAP MENTERI KEUANGAN PURBAYA YUDHI SADEWA MENGGUNAKAN METODE LOGISTIC REGRESSION," *Jurnal Informatika Dan Teknik Elektro Terapan*, 2025.

Lampiran

- Link video presentasi pengajuan ide project :
<https://youtu.be/y-2e6bqf70c?si=APKKFuhtqOQGRReDG>
- Link video Progres Report 1:
<https://youtu.be/WhgBZkPENTo>
- Link video presentasi final project :
<https://youtu.be/AxrAmffuWf4>
- Link Google Colab :
[PEMTEKS FIXXXX PARAHHH.ipynb - Colab](#)